

CC3092 - Deep Learning y Sistemas Inteligentes

Hoja de trabajo #2

Transformers y mecanismos de atención

Instrucciones generales

- Individual.
- Entrega: lunes 05 de octubre, 2026. 23:59.

1. Lecturas y recursos

- Vaswani et al. (2017). Attention Is All You Need. arXiv:1706.03762

Modelos preentrenados para la sección 5.4:

```
from transformers import AutoTokenizer, AutoModel
tok_bert = AutoTokenizer.from_pretrained("bert-base-uncased")
bert = AutoModel.from_pretrained("bert-base-uncased", output_attentions=True, attn_implementation="eager")
tok_gpt2 = AutoTokenizer.from_pretrained("gpt2")
gpt2 = AutoModel.from_pretrained("gpt2", output_attentions=True, attn_implementation="eager")
```

2. Investigación: de las RNN a la atención

Investiguen y respondan con sus propias palabras:

- ¿Qué es el «cuello de botella» del modelo encoder-decoder con RNN (seq2seq) y por qué empeora con oraciones largas? ¿Cómo lo resuelve la atención de Bahdanau?
- Diferencia entre atención aditiva (Bahdanau) y atención multiplicativa o de producto punto (Luong). ¿Cuál es más eficiente en hardware moderno y por qué?
- Expliquen la analogía de consulta (query), llave (key) y valor (value) como una búsqueda «suave» en un diccionario. ¿De dónde salen Q, K y V en self-attention y en cross-attention?
- ¿Qué limitaciones de las RNN (procesamiento secuencial, dependencias de largo alcance, desvanecimiento del gradiente) elimina el Transformer al prescindir de la recurrencia?

3. Investigación: la arquitectura Transformer

Con base en «Attention Is All You Need», describan brevemente el propósito de cada componente y respondan:

- **Scaled dot-product attention:** $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$. ¿Por qué se divide entre $\sqrt{d_k}$? Si los componentes de q y k son independientes con media 0 y varianza 1, ¿cuál es la varianza de $q \cdot k$? ¿Qué le pasa a la softmax y a sus gradientes sin el escalamiento?
- **Multi-head attention:** ¿qué se gana al usar h cabezas de dimensión d_{model}/h en lugar de una sola cabeza de dimensión d_{model} ? ¿Cambia el número de parámetros?
- **Codificación posicional:** ¿por qué la self-attention por sí sola no conoce el orden de los tokens? Describan la codificación sinusoidal y compárenla brevemente con embeddings posicionales aprendidos y con RoPE.
- **Bloque completo:** conexiones residuales, LayerNorm y la red feed-forward por posición. ¿Qué diferencia hay entre Post-LN (artículo original) y Pre-LN (usado en la mayoría de modelos actuales)?

- **Complejidad:** ¿cuál es el costo en tiempo y memoria de la self-attention respecto a la longitud n de la secuencia? Mencionen al menos dos propuestas para reducirlo (por ejemplo FlashAttention, atención por ventanas, atención lineal) y qué sacrifica cada una.

4. Investigación: atención en PyTorch y Hugging Face

Investiguen las clases y funciones necesarias para implementar y analizar atención. Para cada una, describan brevemente su propósito y sus parámetros más relevantes.

- `F.scaled_dot_product_attention` (`attn_mask`, `dropout_p`, `is_causal`, `scale`)
- `nn.MultiheadAttention` (`embed_dim`, `num_heads`, `batch_first`, `kdim`, `vdim`) y los argumentos de su `forward` (`key_padding_mask`, `attn_mask`, `need_weights`, `average_attn_weights`)
- `nn.TransformerEncoderLayer` (`d_model`, `nhead`, `dim_feedforward`, `dropout`, `norm_first`) y `nn.Transformer.generate_square_subsequent_mask`
- En Hugging Face: el argumento `output_attentions` y la forma de las atenciones que devuelve el modelo (una por capa, de tamaño $\text{batch} \times \text{cabezas} \times n \times n$).

5. Ejercicios prácticos

Visualización de atención en modelos preentrenados

Con BERT y GPT-2 (sección 1):

- Grafiquen como mapas de calor los pesos de atención de al menos 4 cabezas de capas distintas para una oración de su elección. Identifiquen patrones: atención al token anterior o siguiente, a [CLS] o [SEP], a la puntuación o a la misma palabra.
- Usen el par «The animal didn't cross the street because it was too tired.» y «... because it was too wide.». Busquen en BERT alguna cabeza en la que «it» atienda más a «animal» en un caso y a «street» en el otro.
- Verifiquen en GPT-2 que la matriz de atención es triangular inferior. ¿Qué proporción de la atención recibe el primer token en cada capa? Investiguen el fenómeno de «attention sinks» (Xiao et al., 2023, arXiv:2309.17453).
- Comparen la entropía promedio de la atención por capa en BERT y en GPT-2. ¿Las capas profundas atienden de forma más difusa o más concentrada?
- Opcional: exploren las mismas oraciones con la librería bertviz.

7. Discusión y análisis

Respondan con base en su investigación y sus resultados:

- ¿Por qué la atención permitió entrenar modelos mucho más grandes que las RNN? Consideren el paralelismo, la longitud del camino entre dos tokens cualesquiera y el costo cuadrático.
- ¿Qué evidencia encontraron de que las cabezas se especializan? ¿Todas las cabezas parecen útiles?
- ¿Los pesos de atención explican las decisiones del modelo? Argumenten con sus visualizaciones y con las lecturas de Jain y Wallace y de Wiegrefe y Pinter.

- ¿En qué casos preferirían todavía una RNN o una CNN sobre un Transformer?
- Si tuvieran que procesar documentos de 100,000 tokens, ¿qué problema enfrentarían con la atención estándar y qué alternativas considerarían?

Entregables

Entregable	Contenido
PDF (máx. 5 páginas)	Investigación (secciones 2 a 4), procedimiento completo del ejercicio a mano, resultados de las verificaciones de la sección 6.1, gráficas de escalamiento y de costo computacional, mapas de atención con su interpretación, discusión, conclusiones y referencias consultadas.
Repositorio (Git)	Jupyter Notebook completo y comentado: implementación y visualizaciones de atención en BERT y GPT-2.

Incluyan el enlace al repositorio al final del PDF.